Laporan v3.1: kalibrasi & paket produksi

Menerapkan keputusan laporan v3 tanpa melatih model baru

0,832
Macro-F1 v3.1*

0,78 → 0,83
Macro-F1 v2 produksi → v3.1

84,7 → 92,4%
Recall Normal

72 → 25
AFL palsu, pasien tanpa AFL**

*Estimasi jujur (bias cross-fit) pada window uji detektor 50 Hz, OOF v3 (5 ulangan × 5 fold pasien), CI 95% 0,67–0,92. **Window per ulangan. Bukan uji pada perangkat asli.

Jawaban singkat
Bias kelas produksi diganti dari [0; 2; −3] menjadi **[0; −0,5; −4,5]**. Pada data uji dan pasien yang sama, sistem menjadi lebih baik secara konsisten dari v2 produksi (Δ Macro-F1 0,053, P = 1,00). Recall Normal, recall AFL, dan precision AFL semuanya naik. Bobot model tidak berubah; yang berubah hanya satu baris di metadata. Paket baru siap dipakai backend lewat *BACKEND.md*.

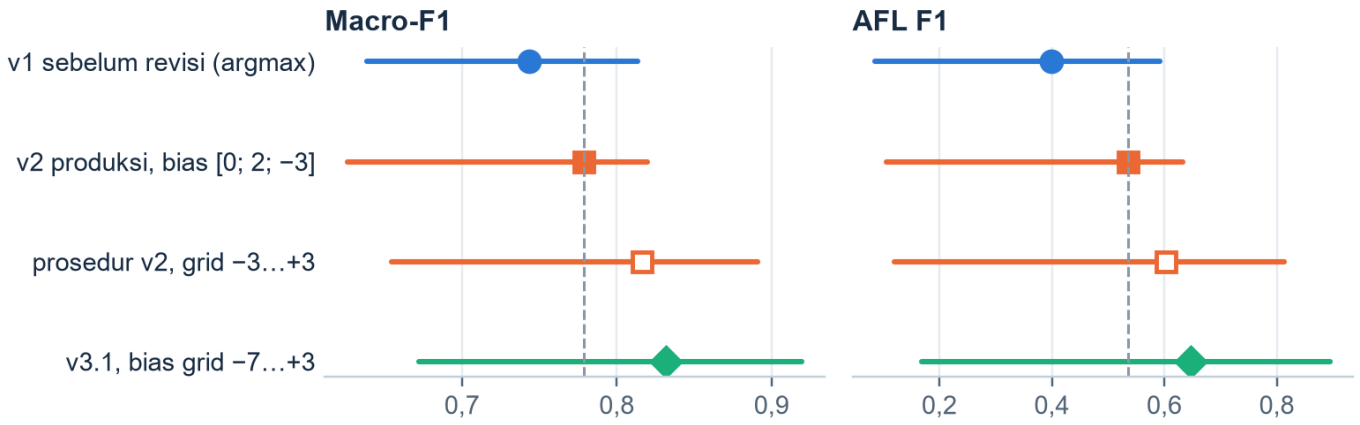
Status lima keputusan dari laporan v3

Keputusan	Status	Bukti / lokasi
1. Ganti sistem lama (final.joblib + *find_peaks*)	**Siap dimigrasi**	Paket *model_export/sihedaf_v3_1* + panduan *BACKEND.md* (hal. 5)
2. Tetap MicroTransformer	Selesai	Bobot v2 dipakai apa adanya, checksum identik
3. Stop arsitektur RR-only	Dicatat	Keputusan proyek di README.md & AGENTS.md root
4. Kalibrasi ulang *class_bias*	**Selesai**	[0; 2; −3] → [0; −0,5; −4,5] (hal. 2–3)
5. Protokol v3 untuk eksperimen berikutnya	Diterapkan	Semua angka di laporan ini memakai fold, seed, & bootstrap v3

Perbandingan dengan versi sebelumnya

Window uji detektor 50 Hz, fold & bootstrap pasien yang sama untuk semua baris

Varian	Macro-F1	AFL F1	AFL P	AFL R	Normal R
v1 (sebelum revisi), argmax	0,744 [0,64–0,81]	0,399 [0,09–0,59]	0,275	0,728	0,903
v2 tanpa bias (argmax)	0,717 [0,62–0,78]	0,313 [0,04–0,48]	0,201	0,711	0,895
v2 produksi: bias tetap [0; 2; −3]	0,779 [0,63–0,82]	0,536 [0,11–0,63]	0,598	0,487	0,847
Prosedur v2: cross-fit grid −3…+3	0,816 [0,65–0,89]	0,603 [0,12–0,81]	0,580	0,630	0,904
v3.1: cross-fit grid −7…+3 (estimasi jujur)	0,832 [0,67–0,92]	0,647 [0,17–0,89]	0,715	0,592	0,924
v3.1: bias tetap baru (optimistis)	0,837 [0,68–0,92]	0,656 [0,17–0,90]	0,719	0,603	0,926



Perbandingan berpasangan	Δ Macro-F1	Δ AFL F1	Δ Normal R	P(Δ MF1>0)
v3.1 vs v2 produksi	0,053 [0,01; 0,12]	0,111 [0,01; 0,31]	0,076 [0,05; 0,11]	1,00
v3.1 vs v1	0,088 [0,02; 0,16]	0,249 [0,05; 0,47]	0,020 [0,01; 0,03]	0,98
v2 produksi vs v1	0,035 [−0,03; 0,07]	0,138 [−0,05; 0,25]	−0,056 [−0,09; −0,03]	0,90
v3.1 bias tetap vs cross-fit (optimisme)	0,005 [0,00; 0,01]	0,008 [0,00; 0,02]	0,002 [−0,00; 0,01]	1,00

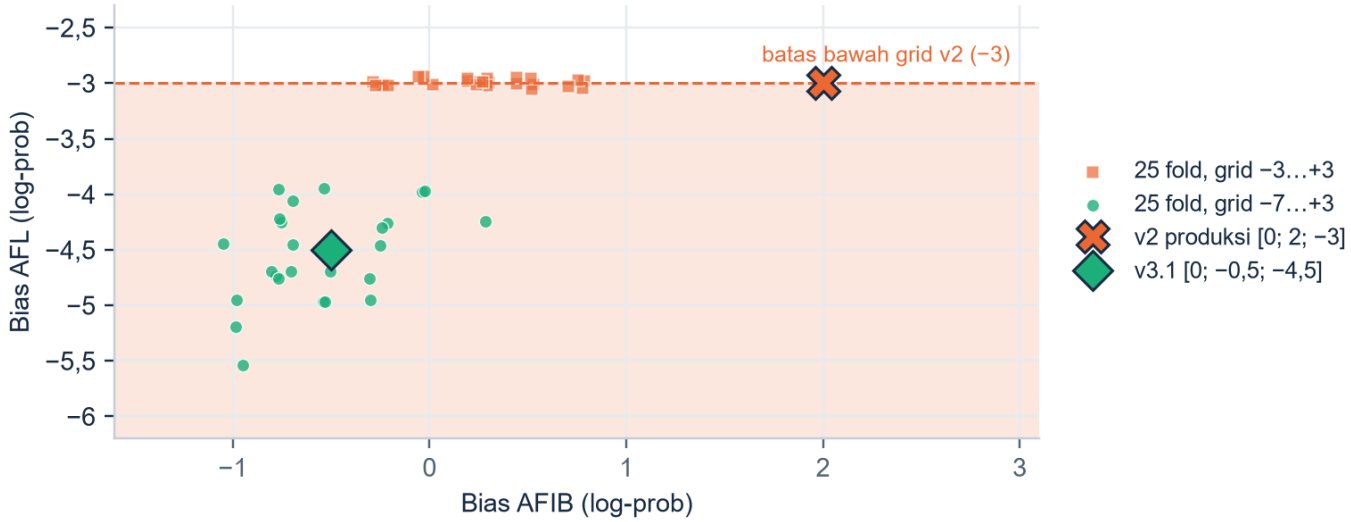
Cara membaca

v3.1 lebih baik secara konsisten dari v2 produksi. Yang mengejutkan: **v2 produksi apa adanya tidak terbedakan dari v1** (P = 0,90), karena bias [0; 2; −3] menurunkan recall Normal ke 84,7%. Baris "bias tetap" memakai bias yang dipilih dari OOF yang sama, jadi sedikit optimistis; selisihnya dari estimasi jujur hanya 0,005, tanda biasnya stabil.

Kenapa bias v2 salah, dan bias baru stabil

Bias per fold (cross-fit) dan efeknya pada model final

Bias kelas menggeser ambang keputusan setelah training. Grid v2 hanya −3…+3, sehingga bias AFL **selalu** berhenti di −3. Pencarian lalu mengakali batas itu dengan menaikkan bias AFIB: tebakan AFL berkurang karena dialihkan ke AFIB, tapi window Normal ikut tertebak AFIB.



Grid	Bias AFIB (median, rentang)	Bias AFL (median, rentang)
−3…+3 (v2)	0,25 (−0,25 … 0,75)	−3,00 (100% di batas grid)
−7…+3 (v3.1)	−0,75 (−1,00 … 0,25)	−4,50 (−5,50 … −4,00)

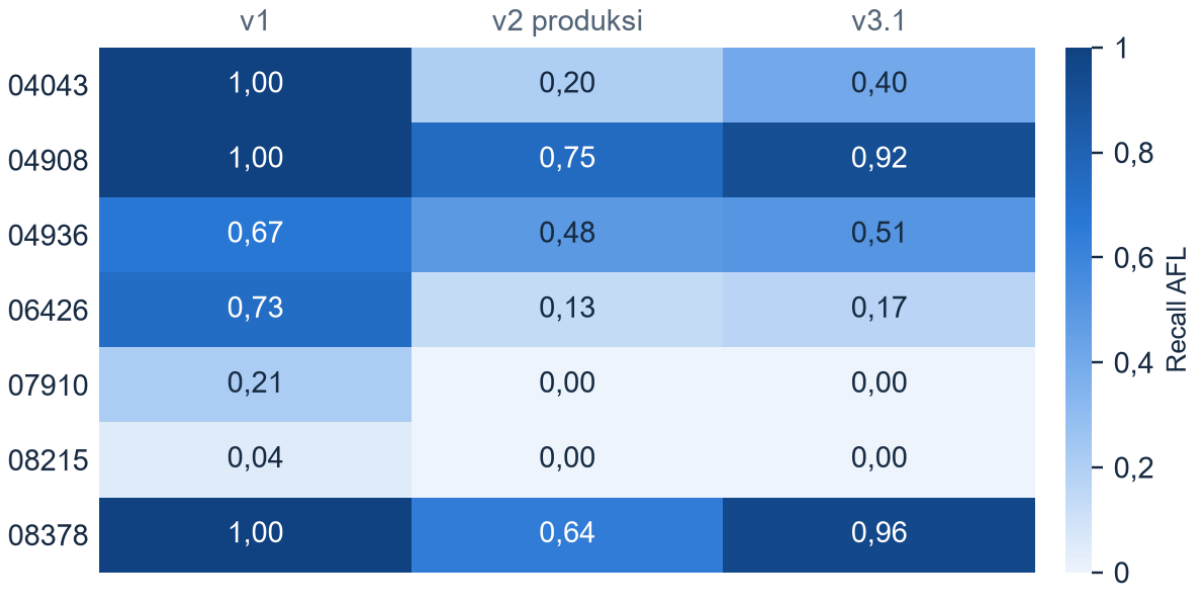
Cek kewajaran pada model final (in-sample)

Sumber	Normal	AFIB	AFL
aktual	59,6%	39,7%	0,7%
v2 [0; 2; −3]	53,4%	46,0%	0,5%
v3.1 [0; −0,5; −4,5]	58,4%	41,0%	0,6%

Artinya
Dengan bias v2, model final menebak AFIB pada 46,0% window, padahal aslinya 39,7%. Dengan bias v3.1, angkanya 41,0%, jauh lebih dekat ke proporsi sebenarnya. Model final dilatih pada semua pasien, jadi tabel ini hanya menunjukkan arah efek bias, bukan akurasi.

AFL per pasien dan alarm palsu

Recall AFL rata-rata 5 ulangan; AFL palsu = window non-AFL yang ditebak AFL



Varian	AFL palsu total	di pasien ber-AFL	di pasien tanpa AFL
v1 (sebelum revisi), argmax	2240	1181	1059
v2 produksi: bias tetap [0; 2; −3]	378	306	72
v3.1: cross-fit grid −7…+3 (estimasi jujur)	274	249	25

Cara membaca

v3.1 menaikkan recall AFL di hampir semua pasien dibanding v2 produksi (paling jelas 08378 dan 04908) sambil menekan AFL palsu pada pasien tanpa AFL dari 72 ke 25 window per ulangan. v1 punya recall tertinggi karena sangat sering menebak AFL: ribuan alarm palsu. 07910 dan 08215 tetap tidak terdeteksi oleh versi mana pun; ini batas data, bukan bias.

Paket produksi dan migrasi backend

Keputusan 1 dan 2: apa yang berubah, bagaimana diuji, cara kembali

File	Isi
model_export/sihedaf_v3_1.pt	Bobot MicroTransformer final v2, **identik** (SHA-256 sama)
model_export/sihedaf_v3_1.json	Metadata v2 + *class_bias* [0; −0,5; −4,5], versi 3.1, asal-usul (*parent*), cara kalibrasi, metrik protokol v3
BACKEND.md	Panduan integrasi: file yang disalin, API, status, perbedaan dengan sistem lama, checklist, rollback
v2_revisi/{hrv_core, sihedaf_models, predictor}.py	Kode inferensi tetap dari v2 (tidak disalin)

Uji paket

Uji	Hasil
Paket v2 tidak berubah	Ya, checksum metadata sama
Paritas predictor vs evaluasi	selisih probabilitas maks 1,5e−7
Prediksi berbeda dari paket v2	5,1% dari 4.000 window acak
Guard satuan & window buruk	IBI dalam detik → error; window < 4 IBI → *tidak_terbaca*
Demo 60 s episode AFL (04936)	v2: 10/11 window AFL · v3.1: 11/11 window AFL (in-sample, uji alur)

Migrasi dan rollback
Backend menyalin tiga file Python dari *v2_revisi/* dan dua file model dari *v3.1_kalibrasi_produksi/model_export/*, lalu memanggil *ECGPredictor("model_export", name="sihedaf_v3_1")*. Kode *find_peaks* dan *final.joblib* dihapus. Karena bobotnya sama, rollback ke v2 cukup mengganti dua file model; kode tidak berubah.

Kesimpulan dan langkah berikutnya

Yang berubah di produksi, yang tetap, dan batasannya

Bias baru dipakai. [0; 2; −3] → [0; −0,5; −4,5]. Lebih baik secara konsisten dari v2 produksi (Macro-F1 0,779 → 0,832) dan dari v1 (P = 0,98).

Model tetap. MicroTransformer v2, bobot identik. Tidak ada training di v3.1.

Trade-off yang tersisa. Recall AFL v3.1 (0,592) masih di bawah v1 (0,728), karena v1 menebak AFL jauh lebih sering (precision 0,275).

Referensi baru. Eksperimen berikutnya dibandingkan dengan **v3.1** (bias cross-fit grid −7…+3) memakai OOF dan fold v3.

Langkah berikutnya (v4)

• Smoothing antar-window dan ensemble MicroTransformer + BiGRU. Keduanya bisa diuji langsung pada OOF v3 tanpa training.

• Window AFL rapat khusus training dan bobot kelas yang lebih lunak (butuh training ulang).

• Untuk pasien 07910, 08215, 06426: cabang EKG mentah 50 Hz atau data AFL tambahan.

Batasan

• Bias dipilih dari OOF model per fold lalu dipasang ke model final (dilatih pada semua pasien), sama seperti di v2. Ini asumsi yang wajar tapi belum bisa diuji di AFDB.

• Semua angka dari 23 pasien AFDB (7 dengan AFL) yang disimulasikan ke 50 Hz. Perlu validasi pada data perangkat asli yang dilabeli dokter.

• Reproduksi: `python tools/run_notebook.py v3.1_kalibrasi_produksi/kalibrasi_produksi.ipynb`, lalu `laporan/build_report.py --extract` dan tanpa argumen.