Laporan v3.2: uji stres takikardia

Evaluasi saja, tanpa training; menindaklanjuti review eksternal atas paket v3.1

±115 bpm
Normal berhenti ditebak (v3.1)

95%
Normal ≥120 bpm asli → alarm

0,993
P(v3.1 > v2), bersarang

0,94
P(v3.1 > v1), tanpa 04936

Jawaban singkat
Temuan reviewer benar. Semua paket (v1, v2, v3.1) berhenti menebak Normal pada ritme teratur di sekitar 110–115 bpm. Pada window Normal asli ≥120 bpm, v3.1 membunyikan alarm AFIB/AFL di 95% window. Penyebabnya data latih: hanya 0,1% window Normal di AFDB yang di atas 120 bpm. Kesimpulan v3–v3.1 tetap berlaku, tetapi sedikit kurang yakin: P(v3.1 > v2) 0,993 setelah pemilihan bias ikut diacak, dan v3.1 vs v1 menjadi tidak terbedakan tanpa pasien 04936 (P = 0,94).

Status klaim review

Klaim	Status	Bukti di laporan ini
Ritme cepat teratur dianggap AFIB/AFL	**Terbukti**	Ambang Normal v3.1 ±115 bpm, semua jenis variasi (hal. 2)
Di 120–130 bpm ditebak AFIB	Sebagian	AFIB jika variasi detak besar; AFL jika hampir tanpa variasi (hal. 2)
Hanya 0,1% Normal > 120 bpm; AFL 78%	**Terbukti**	100 dari 99.000 window Normal; 903 dari 1.152 window AFL
Bias −4,5 tidak menolong	**Terbukti**	v3.1 hanya sedikit lebih baik dari v2 di 110–120 bpm (hal. 3)
Label AFL 04936 tidak bisa dipercaya	Belum terverifikasi	Tidak ada di halaman PhysioNet AFDB; sensitivitas tetap dihitung (hal. 4)
CI belum memasukkan pemilihan bias	**Benar**	Bootstrap bersarang (hal. 4)
Chapman–Shaoxing punya label sinus takikardia	**Terbukti**	Kode ST (SNOMED 427084000) di daftar kondisinya

Cara uji

• **Ritme teratur sintetis** (hal. 2): deretan interval RR buatan 60–170 bpm dengan sedikit variasi acak, lalu dimasukkan ke paket model asli lewat praproses produksi. Secara klinis ritme ini normal (sinus takikardia).

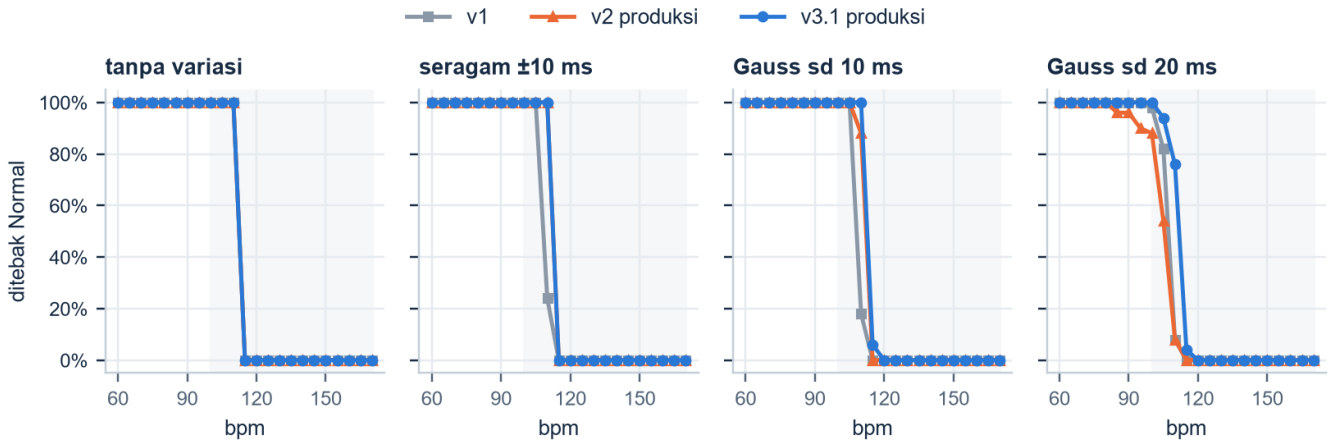
• **Window asli per pita detak** (hal. 3): prediksi OOF (out-of-fold: pasien uji tidak pernah ikut dilatih) dari evaluasi v3–v6, dikelompokkan menurut detak jantung window.

• **Sensitivitas** (hal. 4): evaluasi ulang tanpa pasien 04936, dan CI yang ikut memperhitungkan pemilihan bias kelas.

• **Aturan produk** (hal. 5): berapa banyak window AFDB yang akan diganti labelnya oleh aturan "takikardia teratur".

Uji sintetis: ritme teratur 60–170 bpm

50 window 10 s per titik; model yang punya bobot (v4–v6 tidak menyimpan bobot)



Model	Ambang: tanpa variasi	Ambang: seragam ±10 ms	Ambang: Gauss sd 10 ms	Ambang: Gauss sd 20 ms
v1	115 bpm	110 bpm	110 bpm	110 bpm
v2 produksi	115 bpm	115 bpm	115 bpm	110 bpm
v3.1 produksi	115 bpm	115 bpm	115 bpm	115 bpm

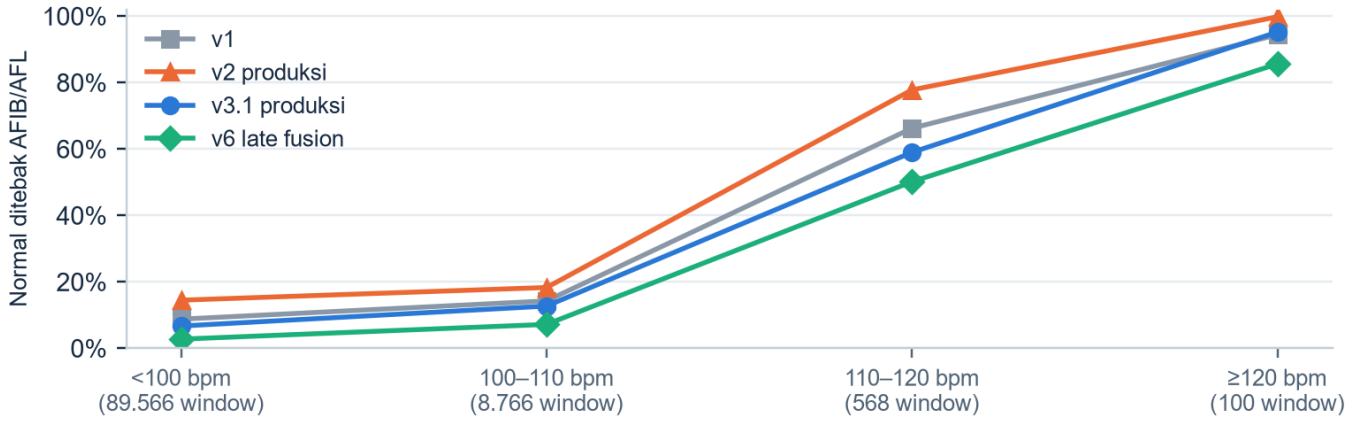
v3.1 di 120 bpm	Normal	AFIB	AFL
tanpa variasi	0%	0%	100%
seragam ±10 ms	0%	0%	100%
Gauss sd 10 ms	0%	40%	60%
Gauss sd 20 ms	0%	100%	0%

Cara membaca

Ambang = detak terendah di mana kurang dari separuh window ditebak Normal. Area abu-abu di grafik = di atas 100 bpm (takikardia); garis yang tidak terlihat tertimpa garis v3.1 karena nilainya sama. Ketiga paket punya ambang di 110–115 bpm, jadi masalah ini sudah ada sejak v1 dan bukan dibuat oleh revisi. Di atas ambang, kelas yang ditebak bergantung pada variasi detak: ritme yang sangat teratur ditebak AFL, variasi sedikit lebih besar (sd 20 ms) ditebak AFIB. Keduanya salah untuk sinus takikardia. Untuk ritme di atas ±140 bpm yang benar-benar teratur, AFL 2:1 memang tidak bisa dibedakan dari interval RR saja.

Window asli per pita detak jantung

Prediksi OOF (rata-rata 5 ulangan) pada window AFDB; semua model yang punya OOF



Kelas & pita (Normal: % alarm; AFL: % terdeteksi)	v1	v2 produksi	v3.1 produksi	v4 ensemble	v5 bobot lunak	v6 late fusion
Normal 100–110 bpm (8.766 window, 12 pasien)	14%	18%	13%	12%	12%	7%
Normal 110–120 bpm (568 window, 10 pasien)	66%	78%	59%	59%	59%	50%
Normal ≥120 bpm (100 window, 7 pasien)	94%	100%	95%	94%	95%	86%
AFL ≥120 bpm (903 window, 5 pasien)	89%	62%	75%	73%	75%	68%

Yang terlihat

Alarm palsu naik tajam mulai 110 bpm untuk semua model: 59% pada 110–120 bpm dan 95% pada ≥120 bpm (v3.1). Late fusion v6 sedikit lebih baik (86%), tetapi masalahnya sama. v1 mendeteksi AFL cepat paling banyak (89%) karena cenderung menyebut semua ritme cepat AFL: 25% window AFIB ≥120 bpm juga ditebak AFL. Window Normal cepat di AFDB justru **tidak** teratur (koefisien variasi median 0,18 vs 0,025 untuk semua Normal), kemungkinan karena denyut ektopik di pasien AF. Sinus takikardia teratur hampir tidak ada di AFDB, jadi skala masalah di dunia nyata belum bisa diukur dengan data ini.

Sensitivitas: tanpa 04936 dan bootstrap bersarang

Apakah kesimpulan v3/v3.1 bergantung pada satu pasien atau pada pemilihan bias?

Pasien 04936 menyumbang 58% window AFL. Reviewer menyebut labelnya dipertanyakan; halaman PhysioNet AFDB tidak menyebut hal ini, jadi sumbernya belum terverifikasi. Window 04936 dikeluarkan dari evaluasi (bias cross-fit dihitung ulang tanpa dia); model tidak dilatih ulang.

Data	Model	Macro-F1	AFL F1	AFL recall	P(v3.1 > model)
semua pasien	v1	0,744 [0,64–0,81]	0,399 [0,09–0,59]	0,728 [0,37–0,98]	0,98 (lebih baik)
	v2 produksi	0,779 [0,63–0,82]	0,536 [0,11–0,63]	0,487 [0,11–0,63]	1,00 (lebih baik)
	v3.1 produksi	0,832 [0,67–0,92]	0,647 [0,17–0,89]	0,592 [0,13–0,91]	—
tanpa 04936	v1	0,720 [0,62–0,82]	0,322 [0,04–0,61]	0,813 [0,25–0,99]	0,94 (tidak terbedakan)
	v2 produksi	0,763 [0,60–0,83]	0,492 [0,01–0,65]	0,490 [0,01–0,65]	1,00 (lebih baik)
	v3.1 produksi	0,859 [0,62–0,92]	0,725 [0,02–0,90]	0,663 [0,02–0,89]	—

Bootstrap bersarang (bias dipilih ulang di setiap sampel)

CI di v3 dihitung dari prediksi yang biasnya sudah dipilih sekali per fold, lalu pasien diambil ulang 2.000 kali. Padahal bias itu sendiri dipilih dari data, jadi bisa saja berbeda bila pasiennya berbeda. Pada bootstrap **bersarang**, untuk setiap sampel pasien, bias v3.1 dipilih ulang dari pasien latih yang terambil, lalu dipasang ke pasien uji. Ketidakpastian pemilihan bias ikut masuk ke CI, sehingga CI-nya lebih lebar dan lebih jujur.

Perbandingan	Δ Macro-F1	CI 95% bersarang	P(Δ>0) bersarang	P(Δ>0) v3 (bias tetap)
v3.1 vs v2 produksi	+0,053	+0,007 … +0,112	0,993	1,000
v3.1 vs v1	+0,088	+0,005 … +0,149	0,978	0,985

Artinya
Keunggulan v3.1 atas v2 bertahan di kedua uji (P ≥ 0,99). Keunggulan atas v1 lebih rapuh: tetap konsisten setelah pemilihan bias diacak (P = 0,978), tetapi tanpa 04936 turun ke P = 0,94 (tidak terbedakan). Klaim "P = 1,00" di laporan v3.1 memang terlalu yakin; angka bersarang di sini yang lebih jujur.

Simulasi aturan produk

Detak ≥ H bpm DAN ritme teratur (koefisien variasi IBI ≤ C) → "takikardia teratur, perlu dicek"

Aturan ini tidak memperbaiki model; ia mengganti label keluaran untuk ritme cepat yang teratur. Ritme sinus takikardia teratur hampir tidak ada di AFDB, jadi **manfaatnya tidak bisa diukur di sini**. Yang bisa diukur adalah harganya: berapa banyak deteksi AFL yang ikut dialihkan, karena AFL 2:1 juga cepat dan teratur.

Aturan	Normal kena	AFIB kena	AFL kena	Alarm palsu dialihkan	AFL terdeteksi dialihkan
≥100 bpm & CV ≤ 0,03	6,5%	0,1%	40,0%	0,7%	60,3%
≥100 bpm & CV ≤ 0,05	6,7%	0,2%	57,3%	1,1%	86,0%
≥100 bpm & CV ≤ 0,08	6,9%	0,7%	68,2%	2,2%	96,9%
≥110 bpm & CV ≤ 0,03	0,1%	0,1%	39,5%	0,7%	60,3%
≥110 bpm & CV ≤ 0,05	0,1%	0,2%	56,7%	0,9%	86,0%
≥110 bpm & CV ≤ 0,08	0,1%	0,4%	67,6%	1,2%	96,9%
≥120 bpm & CV ≤ 0,03	0,0%	0,1%	37,2%	0,1%	60,3%
≥120 bpm & CV ≤ 0,05	0,0%	0,2%	54,0%	0,2%	86,0%
≥120 bpm & CV ≤ 0,08	0,0%	0,3%	64,9%	0,3%	96,9%

Kena = % window kelas itu (label asli) yang memenuhi aturan. *Alarm palsu dialihkan* = % window Normal yang ditebak AFIB/AFL dan diganti labelnya oleh aturan. *AFL terdeteksi dialihkan* = % window AFL yang benar ditebak AFL lalu diganti labelnya. CV = koefisien variasi IBI (simpangan baku / rata-rata); makin kecil, makin teratur.

Keteraturan (koefisien variasi IBI, median)	Nilai
Window AFL (AFDB)	0,030
Window AFIB (AFDB)	0,213
Sintetis Gauss sd 20 ms @ 120 bpm	0,039
Sintetis Gauss sd 20 ms @ 170 bpm	0,056

Trade-off untuk pemilik produk

Dengan aturan ≥110 bpm & CV ≤ 0,05 (baris disorot), hampir semua ritme teratur sintetis (CV 0–0,056) tidak lagi dilaporkan sebagai AFIB/AFL dan AFIB nyaris tidak tersentuh (0,2%). Tetapi 86% AFL yang berhasil dideteksi berubah label menjadi "takikardia teratur, perlu dicek". Pengguna tetap diberi peringatan, hanya tidak disebut AFL. Mau tidaknya memakai aturan ini adalah keputusan produk, bukan keputusan teknis.

Kesimpulan dan langkah berikutnya

Yang berubah setelah review, dan yang belum bisa dijawab

Hal	Keputusan / status
Paket produksi v3.1	Tetap; tidak ada perubahan bobot atau bias
BACKEND.md	Ditambah peringatan: ritme teratur ≥ ±115 bpm dilaporkan AFIB/AFL
Protokol evaluasi (AGENTS.md)	Uji stres takikardia wajib untuk setiap model baru; CI bersarang disarankan
Aturan produk "takikardia teratur"	**Menunggu keputusan pemilik produk** (trade-off di hal. 5)
Klaim di laporan v3.1 (P = 1,00)	Dikoreksi: P = 0,993 dengan pemilihan bias ikut diacak

Langkah berikutnya

• **v7 dengan data eksternal yang memuat sinus takikardia** (mis. Chapman–Shaoxing: label ST, SVT, AF/flutter). Sekaligus menambah pasien AFL dan memungkinkan model belajar bahwa cepat tidak berarti tidak normal.

• Validasi pada rekaman perangkat asli saat aktivitas (naik tangga, olahraga ringan).

• Mencari sumber literatur soal anotasi 04936 sebelum memutuskan mengeluarkannya dari data latih.

Batasan

• Uji sintetis memakai ritme dengan variasi acak sederhana; sinus takikardia sungguhan punya pola variabilitas sendiri.

• Analisis tanpa 04936 hanya mengeluarkannya dari evaluasi, tidak dari training.

• Model v4–v6 tidak menyimpan bobot, jadi hanya diuji di window AFDB (hal. 3), tidak di data sintetis.

• Bootstrap bersarang hanya dihitung untuk Macro-F1 v3.1 vs v2 dan v1.

• Reproduksi: `python tools/run_notebook.py v3.2_uji_takikardia/uji_takikardia.ipynb` (±10 menit pertama kali, CPU), lalu `laporan/build_report.py --extract` dan tanpa argumen.