Laporan v3: evaluasi robust SIHEDAF

Langkah 1: memastikan perbedaan antar model itu nyata, bukan kebetulan | data detektor 50 Hz

0,832	0,647	71,5%	0,74 → 0,83
Macro-F1 model produksi*	AFL F1 model produksi*	Precision AFL*	Macro-F1 lama → sekarang**

*MicroTransformer + bias kelas (grid baru), rata-rata 5 ulangan prediksi out-of-fold. Rentang ketidakpastian (CI 95%) Macro-F1 0,67–0,92, AFL F1 0,17–0,89. **Versi sebelum revisi dilatih ulang dengan resep aslinya pada fold yang sama, diuji pada window yang sama. Ini **bukan** hasil uji pada perangkat asli.

Jawaban singkat
Dibanding **versi sebelum revisi**, sistem sekarang lebih baik secara konsisten: pada data uji yang sama, Macro-F1 0,744 → 0,832 dan AFL F1 0,399 → 0,647. Jika front-end lama ikut dihitung, versi lama hanya Macro-F1 0,418. Di antara empat kandidat model, MicroTransformer + bias tetap yang terbaik; mengganti arsitektur berbasis interval RR tidak menambah apa-apa. Batas yang tersisa adalah **data AFL yang sangat sedikit** (7 pasien).

Temuan utama

1. Revisi memperbaiki versi lama secara nyata. Pada window uji yang sama, AFL precision naik 27,5% → 71,5% (P(Δ Macro-F1 > 0) = 0,98), dengan harga recall AFL turun 72,8% → 59,2%. Sebagian besar kenaikan berasal dari bias kelas. Front-end *find_peaks* lama membuat recall Normal jatuh ke 33,7%.

2. Klaim lama hanya berlaku di kondisi lab. Macro-F1 0,826 di model.ipynb bisa direproduksi (0,803 ± 0,039) dengan R-peak anotasi 250 Hz dan cara lapor lama, tapi tidak di kondisi perangkat 50 Hz.

3. Model produksi sudah terbaik di antara kandidat. Semua varian lain lebih buruk secara konsisten, kecuali BiGRU + bias yang setara (selisih Macro-F1 −0,002). ResNet1D yang unggul di notebook revisi tidak bertahan.

4. Bias kelas produksi terpotong. Bias AFL optimal berada di −5,5 … −4,0, selalu di bawah batas grid revisi (−3). Dengan grid diperlebar, AFL F1 naik 0,603 → 0,647 tanpa melatih ulang.

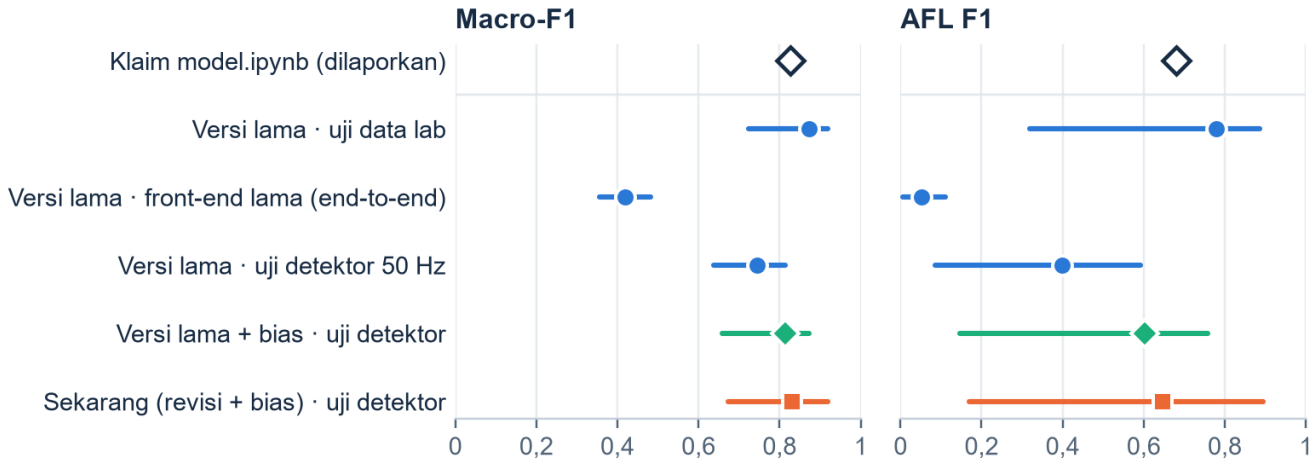
5. Batasnya di data, bukan di model. Pasien 07910 dan 08215 jarang terdeteksi AFL oleh versi mana pun, termasuk versi lama (recall ≤ 0,21).

Panduan baca: sebelum vs sesudah revisi (2–3), kenapa evaluasi dibenahi (4), protokol (5), hasil antar model (6), perbandingan berpasangan (7), bias kelas (8), AFL per pasien (9), kesimpulan (10), lampiran (11).

Sebelum vs sesudah revisi

Versi lama dilatih ulang dengan resep aslinya pada fold pasien yang sama, lalu diuji di tiga kondisi

Versi	R-peak (front-end)	Data latih	Keputusan kelas
Versi lama model.ipynb, final.joblib	*find_peaks* polos di backend, tanpa filter dan tanpa cek kualitas	ekstraksi_hrv.py: R-peak anotasi 250 Hz, stride AFL 1 s (overlap 90%)	argmax
Revisi revisi_sihedaf_v2.ipynb	detektor Pan-Tompkins 50 Hz + cek kualitas window	R-peak detektor 50 Hz, stride 5 s untuk semua kelas	bias kelas, grid −3…+3
Sekarang laporan ini	sama dengan revisi	sama dengan revisi	bias kelas, grid −7…+3



Tiga kondisi uji untuk versi lama: **data lab** = window ekstraksi lama (dipakai model.ipynb untuk melapor skor); **uji detektor 50 Hz** = window yang sama persis dengan yang dipakai menguji model sekarang; **front-end lama** = sinyal 50 Hz diproses seperti backend lama (*find_peaks*), yaitu sistem lama secara utuh. Belah ketupat kosong = skor yang dilaporkan model.ipynb (tanpa CI; AFL F1 dihitung dari precision & recall rata-rata fold).

Intinya

Pada window uji yang sama, sistem sekarang lebih baik secara konsisten dari versi lama: Macro-F1 0,744 → 0,832, AFL F1 0,399 → 0,647, AFL precision 27,5% → 71,5%. Harganya: recall AFL turun 72,8% → 59,2%, artinya alarm palsu jauh berkurang tetapi lebih banyak window AFL yang terlewat. Skor tinggi versi lama hanya muncul di kondisi lab. Dengan front-end aslinya, versi lama hampir tidak bisa dipakai: Macro-F1 0,418, recall Normal 33,7%.

Kenapa front-end lama runtuh?

find_peaks dipakai langsung pada sinyal mentah dengan ambang = rata-rata sinyal dan jarak minimum 0,4 detik (maksimal 150 bpm). Tanpa filter, gelombang T dan noise ikut terdeteksi atau detak terlewat. Nilai IBI-nya masih terlihat wajar (hanya 0,2% window yang akan ditolak cek kualitas revisi), tetapi urutannya kacau, sehingga ritme normal terlihat tidak teratur dan sering ditebak AFIB (recall Normal 33,7%).

Rincian perbandingan dengan versi lama

Semua baris kecuali klaim: rata-rata 5 ulangan × 5 fold pasien, CI 95% bootstrap pasien

Kondisi	Macro-F1	AFL F1	AFL P	AFL R	Normal R
Klaim model.ipynb (rata-rata per fold, satu partisi)	0,826 ± 0,084	≈ 0,681	0,614	0,763	0,927
Versi lama · data lab, **cara lapor lama** (rata-rata per fold)	0,803 ± 0,039	–	–	–	–
Versi lama · data lab (pooled)	0,873 [0,72–0,92]	0,778 [0,32–0,89]	0,745 [0,27–0,87]	0,815 [0,38–0,98]	0,938
Versi lama · front-end lama	0,418 [0,36–0,48]	0,051 [0,00–0,11]	0,027 [0,00–0,06]	0,410 [0,19–0,92]	0,337
Versi lama · uji detektor 50 Hz	0,744 [0,64–0,81]	0,399 [0,09–0,59]	0,275 [0,05–0,46]	0,728 [0,37–0,98]	0,903
Versi lama + bias · uji detektor	0,814 [0,66–0,87]	0,601 [0,15–0,76]	0,652 [0,17–0,90]	0,562 [0,11–0,76]	0,923
Revisi tanpa bias · uji detektor	0,717 [0,62–0,78]	0,313 [0,04–0,48]	0,201 [0,02–0,35]	0,711 [0,31–0,98]	0,895
Sekarang (revisi + bias) · uji detektor	0,832 [0,67–0,92]	0,647 [0,17–0,89]	0,715 [0,26–0,95]	0,592 [0,13–0,91]	0,924

Dari mana perbaikannya? (semua pada window uji detektor yang sama)

Perubahan dari versi lama	Δ Macro-F1 [CI]	Δ AFL F1 [CI]	Δ AFL P [CI]	P(Δ Macro-F1>0)
Hanya menambah bias kelas	0,070 [0,00; 0,12]	0,203 [0,02; 0,36]	0,376 [0,13; 0,60]	0,98
Hanya melatih ulang di data detektor 50 Hz	−0,027 [−0,07; 0,00]	−0,086 [−0,21; −0,01]	−0,075 [−0,19; −0,01]	0,03
Keduanya (= sistem sekarang)	0,088 [0,02; 0,16]	0,249 [0,05; 0,47]	0,440 [0,22; 0,65]	0,98

Cara membaca tabel di atas

Sekitar 80% kenaikan Macro-F1 berasal dari **bias kelas** (Δ 0,070 dari total 0,088). Melatih ulang di data detektor **tanpa** bias justru sedikit lebih buruk (−0,027, P = 0,03); kemungkinan karena versi lama memakai window AFL yang jauh lebih rapat (stride 1 detik), yang ternyata membantu saat *training*. Digabung dengan bias, data detektor tetap memberi tambahan kecil tapi konsisten (0,018 di atas versi lama + bias, P = 0,99).

Kenapa klaim lama terlihat tinggi?

Ekstraksi lama menggeser window AFL tiap 1 detik, sehingga ada 4.925 window AFL (data detektor: 1.152) yang 90% isinya tumpang tindih; 2.545 di antaranya (lebih dari separuh) berasal dari satu pasien, 04936. R-peak-nya dari anotasi 250 Hz yang bersih, bukan dari sinyal perangkat 50 Hz, dan skor dirata-rata per fold pada satu partisi. Resepnya sendiri jujur (pasien tidak bocor antar fold), tapi kondisi ujinya jauh lebih mudah daripada kondisi perangkat.

Kenapa evaluasi perlu dibenahi

Masalahnya ada di cara mengukur, bukan hanya di modelnya

Versi lama (*model.ipynb*) dan notebook revisi sama-sama mengevaluasi tiap model **satu kali** dengan 5 fold dan satu pembagian pasien. Di notebook revisi, selisih Macro-F1 antar model (0,68–0,76) lebih kecil daripada naik-turunnya skor antar fold (± 0,10–0,12); di versi lama, Macro-F1 dilaporkan 0,826 ± 0,084. Dari tabel seperti itu belum bisa disimpulkan model mana yang lebih baik.

Masalah yang ditemukan

#	Masalah	Perbaikan
1	Hanya satu pembagian pasien; hasil bisa kebetulan	5 ulangan × 5 fold, pasien diacak ulang tiap ulangan
2	**StratifiedGroupKFold(shuffle=True)** menghasilkan pembagian pasien AFL yang **sama persis** untuk seed berapa pun (lihat tabel di bawah)	Pasien diacak di dalam 3 strata (AFL / dominan AFIB / lainnya), lalu dibagikan bergiliran ke fold
3	Tidak ada rentang ketidakpastian	Bootstrap tingkat pasien 2.000× → CI 95%
4	Model dibandingkan tanpa pasangan	Selisih dihitung pada sampel bootstrap yang sama (berpasangan)
5	Tabel utama memakai R-peak anotasi, padahal produksi memakai detektor 50 Hz	Semua evaluasi di data detektor

Bukti masalah #2: pasien AFL di fold uji

Pembagian	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
SGKF, seed 0	08378	04936, 08215	04043, 06426	04908	07910
SGKF, seed 1	08378	04936, 08215	04043, 06426	04908	07910
SGKF, seed 2	08378	04936, 08215	04043, 06426	04908	07910
SGKF, seed 3	08378	04936, 08215	04043, 06426	04908	07910
SGKF, seed 4	08378	04936, 08215	04043, 06426	04908	07910
baru, ulangan 0	08215	04908	08378	04043, 07910	04936, 06426
baru, ulangan 1	06426, 08215	04043, 08378	07910	04936	04908
baru, ulangan 2	08215	06426	04936, 08378	04908, 07910	04043
baru, ulangan 3	08378	06426	04908	07910, 08215	04043, 04936
baru, ulangan 4	04908	04936	07910	08215, 08378	04043, 06426

Kenapa pembagian SGKF selalu sama?
StratifiedGroupKFold mengurutkan pasien berdasarkan sebaran kelasnya, dan *shuffle* hanya mengacak pasien yang sebarannya kembar. Dengan 23 pasien yang sebarannya berbeda-beda, hampir tidak ada yang kembar, sehingga seed apa pun memberi pembagian yang sama. Mengulang CV dengan seed lain jadi tidak menambah informasi.

Cara kerja protokol baru

Dari 23 pasien sampai angka dengan rentang ketidakpastian

1 Strata pasien

7 punya AFL · 7 dominan AFIB · 9 lainnya

2 Bagi ke fold

5 ulangan × 5 fold; pasien diacak per strata, dibagi bergiliran

3 Latih & prediksi

Tiap window diprediksi model yang tidak pernah melihat pasiennya (OOF)

4 Bias kelas

Penggeser ambang dipelajari dari fold lain (cross-fit)

5 Bootstrap pasien

Pasien diambil ulang 2.000× → CI 95% dan selisih berpasangan

Data: 165.978 window 10 detik dari 23 pasien AFDB (Normal 99.000, AFIB 65.826, AFL 1.152). R-peak berasal dari detektor 50 Hz, sama dengan kondisi perangkat. Empat model diuji: LightGBM (16 fitur HRV), MicroTransformer, ResNet1D, dan BiGRU (sekuens 30 interval RR). Hiperparameter sama dengan notebook revisi.

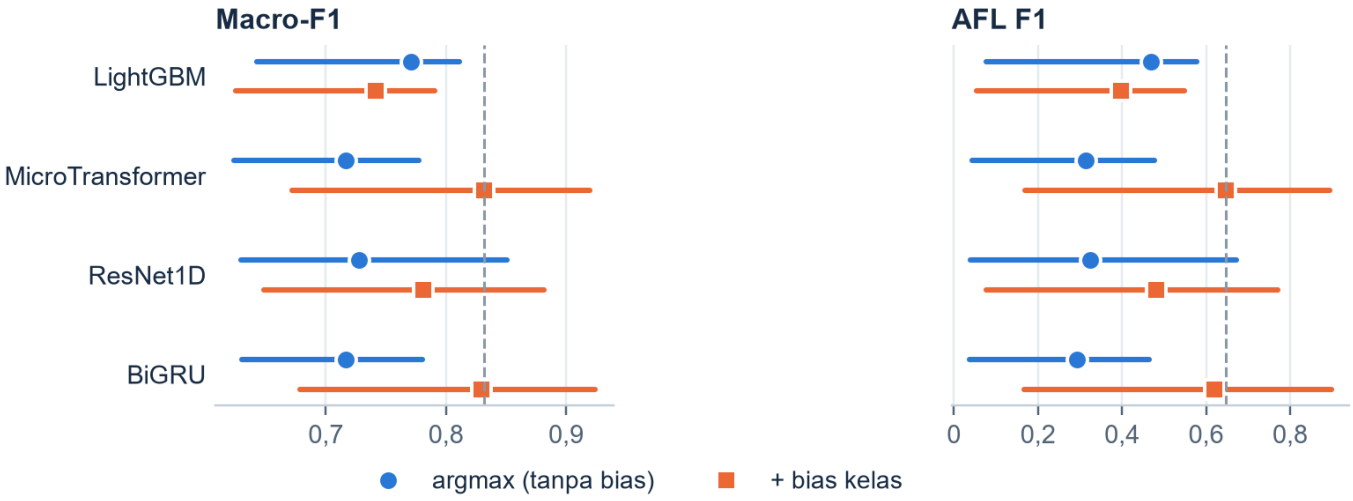
Istilah yang dipakai

Istilah	Arti sederhana
OOF (out-of-fold)	Prediksi untuk pasien yang tidak ikut dilatih. Ini yang membuat skor jujur.
Precision AFL	Dari semua tebakan AFL, berapa persen yang memang AFL. Rendah = banyak alarm palsu.
Recall AFL	Dari semua window AFL sebenarnya, berapa persen yang tertangkap. Rendah = banyak AFL terlewat.
F1	Rata-rata harmonik precision dan recall; tinggi hanya jika keduanya tinggi.
Macro-F1	Rata-rata F1 tiga kelas (Normal, AFIB, AFL) dengan bobot sama, jadi AFL yang langka tetap dihitung penuh.
Bias kelas	Angka yang menggeser ambang keputusan tiap kelas setelah model selesai dilatih. Negatif untuk AFL = model harus lebih yakin sebelum menyebut AFL.
CI 95%	Rentang tempat skor sebenarnya kemungkinan besar berada. Lebar = masih banyak ketidakpastian.
Bootstrap pasien	Mengambil ulang pasien secara acak (boleh terulang) ribuan kali untuk melihat seberapa besar skor berubah jika pasiennya berbeda.
P(Δ > 0)	Peluang model lebih baik dari model produksi. ≥ 0,95 = lebih baik; ≤ 0,05 = lebih buruk; selebihnya = tidak terbedakan.

Hasil utama

Rata-rata 5 ulangan, CI 95% bootstrap pasien | data detektor | baris hijau = model produksi

Model	Macro-F1	AFL F1	AFL P	AFL R	AFIB F1	Normal R
MicroTransformer + bias	0,832 [0,67–0,92]	0,647 [0,17–0,89]	0,715 [0,26–0,95]	0,592 [0,13–0,91]	0,909	0,924
MicroTransformer argmax	0,717 [0,62–0,78]	0,313 [0,04–0,48]	0,201 [0,02–0,35]	0,711 [0,31–0,98]	0,907	0,895
BiGRU + bias	0,829 [0,68–0,92]	0,621 [0,17–0,90]	0,692 [0,19–0,95]	0,564 [0,15–0,92]	0,921	0,934
BiGRU argmax	0,717 [0,63–0,78]	0,293 [0,04–0,46]	0,185 [0,02–0,34]	0,704 [0,31–0,98]	0,918	0,909
ResNet1D + bias	0,781 [0,65–0,88]	0,482 [0,08–0,77]	0,473 [0,07–0,93]	0,521 [0,12–0,77]	0,918	0,944
ResNet1D argmax	0,728 [0,63–0,85]	0,324 [0,04–0,67]	0,218 [0,02–0,59]	0,678 [0,27–0,97]	0,924	0,906
LightGBM + bias	0,742 [0,63–0,79]	0,397 [0,05–0,55]	0,421 [0,05–0,64]	0,376 [0,06–0,57]	0,896	0,928
LightGBM argmax	0,770 [0,64–0,81]	0,468 [0,08–0,58]	0,449 [0,05–0,65]	0,493 [0,13–0,60]	0,907	0,919

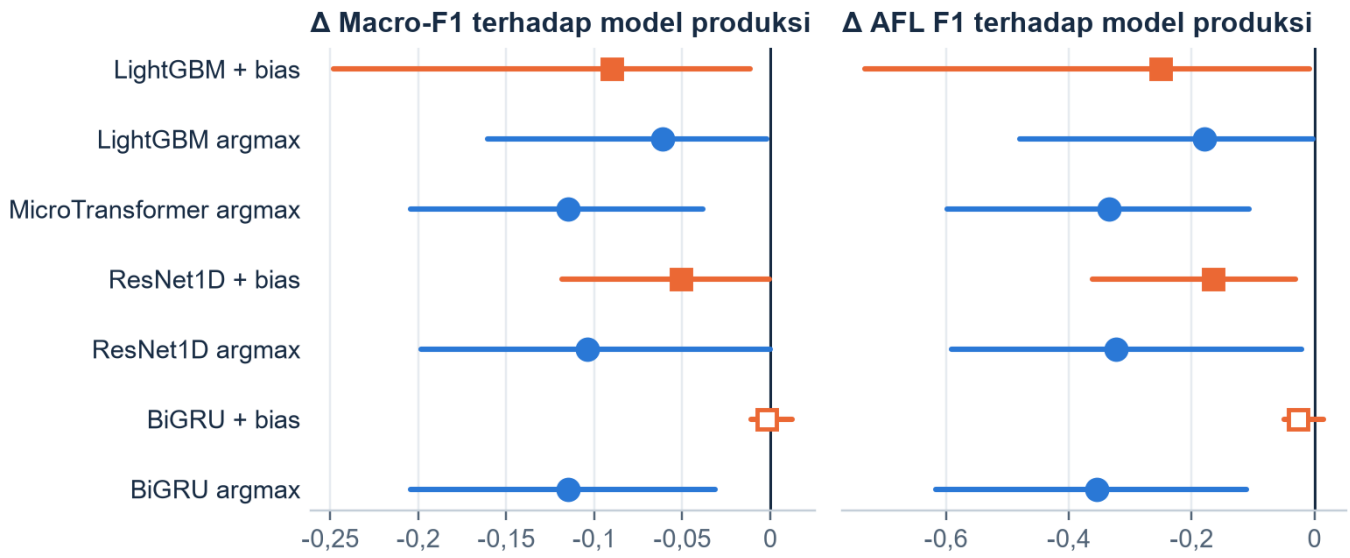


Cara membaca

Titik = skor rata-rata, garis = CI 95%. Garis putus-putus = model produksi. Hampir semua garis AFL F1 sangat panjang (sekitar 0,2–0,9) karena hanya ada 7 pasien AFL: skor sangat bergantung pada pasien mana yang ikut. Karena CI tunggal selebar ini, melihat apakah dua garis tumpang tindih **tidak cukup** untuk membandingkan model. Halaman berikutnya memakai perbandingan berpasangan yang lebih tajam.

Perbandingan berpasangan

Setiap model dibandingkan dengan model produksi (MicroTransformer + bias) pada sampel pasien yang sama



Titik terisi = lebih buruk secara konsisten; titik kosong = tidak terbedakan. Garis = CI 95%. Kiri dari garis 0 = lebih buruk dari produksi.

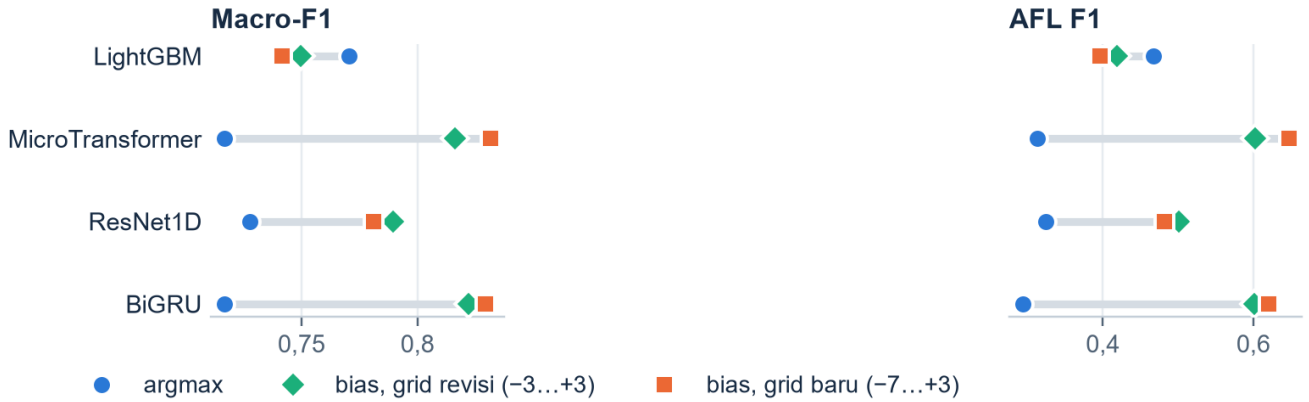
Model	Δ Macro-F1 [CI 95%]	P(Δ>0)	Vonis	Δ AFL F1 [CI 95%]	P(Δ>0)	Vonis
BiGRU + bias	−0,002 [−0,01; 0,01]	0,39	tidak terbedakan	−0,027 [−0,05; 0,02]	0,11	tidak terbedakan
BiGRU argmax	−0,115 [−0,20; −0,03]	0,01	lebih buruk	−0,354 [−0,62; −0,11]	0,01	lebih buruk
ResNet1D + bias	−0,051 [−0,12; −0,00]	0,02	lebih buruk	−0,165 [−0,36; −0,03]	0,01	lebih buruk
ResNet1D argmax	−0,104 [−0,20; 0,00]	0,03	lebih buruk	−0,323 [−0,59; −0,02]	0,01	lebih buruk
LightGBM + bias	−0,090 [−0,25; −0,01]	0,00	lebih buruk	−0,250 [−0,73; −0,01]	0,01	lebih buruk
LightGBM argmax	−0,061 [−0,16; −0,00]	0,02	lebih buruk	−0,179 [−0,48; −0,00]	0,03	lebih buruk
MicroTransformer argmax	−0,115 [−0,20; −0,04]	0,00	lebih buruk	−0,334 [−0,60; −0,11]	0,01	lebih buruk

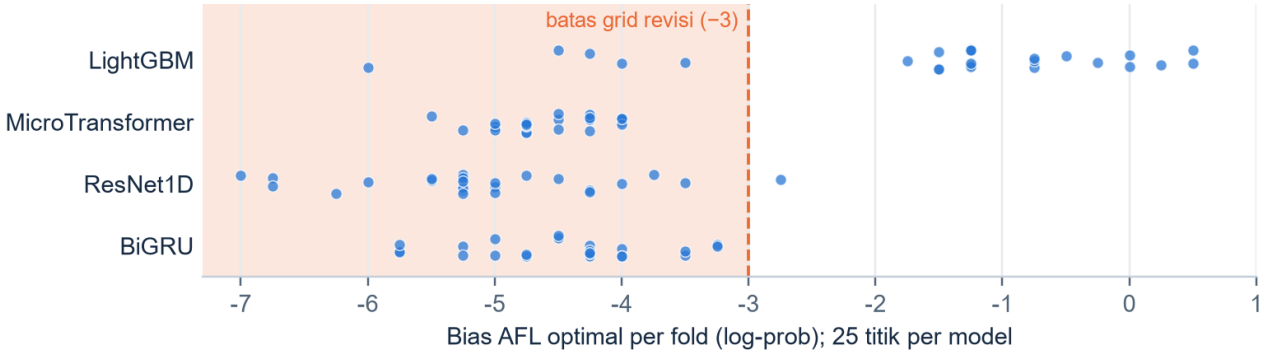
Kenapa CI tunggal lebar tapi selisihnya tetap jelas?
Pasien yang sulit (misalnya 07910) sulit untuk **semua** model. Saat dua model dibandingkan pada pasien yang sama, kesulitan itu saling meniadakan, jadi yang tersisa adalah perbedaan modelnya sendiri. Contohnya, ResNet1D + bias lebih rendah 0,051 Macro-F1 dengan P(Δ>0) = 0,02: kecil, tapi konsisten. BiGRU + bias benar-benar setara dengan produksi (P = 0,39).

Bias kelas: perbaikan termurah

Pengaruh bias dan lebar grid pencariannya, pada OOF dan fold yang sama

Model DL dilatih dengan *weighted cross-entropy*: kesalahan pada AFL diberi bobot sekitar 48× karena AFL sangat langka. Akibatnya model terlalu sering menebak AFL. Bias kelas mengoreksi ini setelah training dengan menggeser ambang keputusan. Notebook revisi mencari bias di rentang −3…+3.





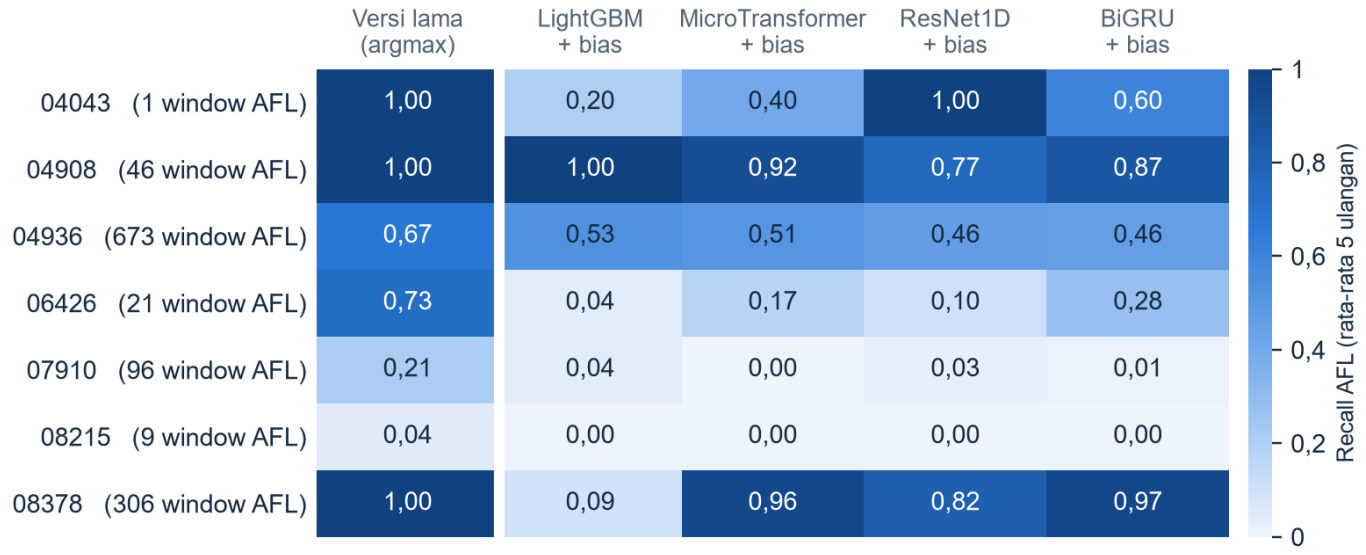
Model	Macro-F1 grid revisi	Macro-F1 grid baru	AFL F1 grid revisi	AFL F1 grid baru	AFL P grid revisi	AFL P grid baru	Bias AFL (median)
MicroTransformer	0,816	0,832	0,603	0,647	0,580	0,715	−4,50
BiGRU	0,822	0,829	0,601	0,621	0,614	0,692	−4,25
ResNet1D	0,790	0,781	0,501	0,482	0,436	0,473	−5,25
LightGBM	0,750	0,742	0,419	0,397	0,431	0,421	−1,25

Artinya untuk model produksi

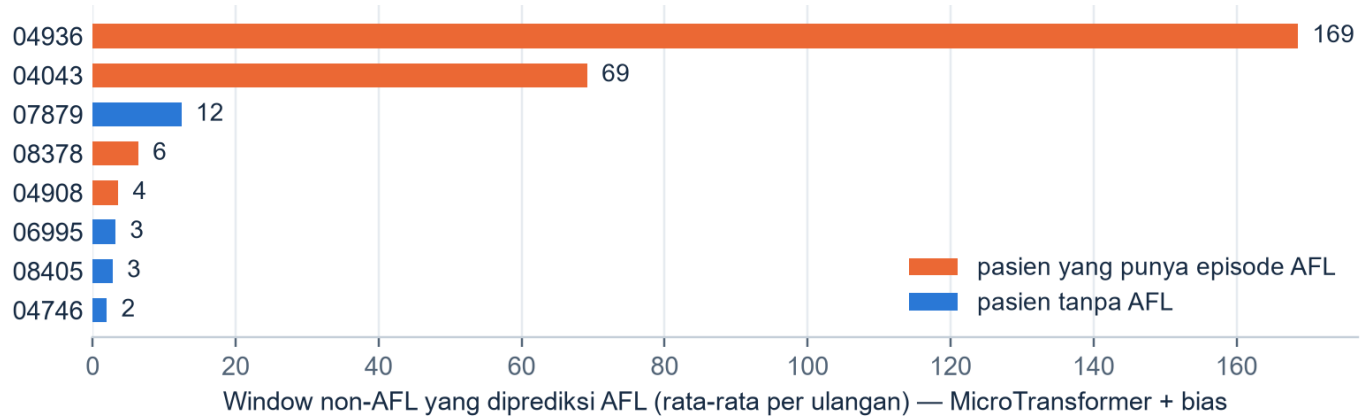
Bias AFL optimal MicroTransformer selalu di −5,5 … −4,0, sedangkan bias produksi **[0, 2, −3]** berhenti tepat di batas grid revisi. Dengan grid diperlebar, precision AFL naik 58,0% → 71,5% dan AFL F1 0,603 → 0,647. Cukup mengubah *class_bias* di sihedaf_v2.json; bobot model tetap. Catatan: untuk ResNet1D dan LightGBM, grid lebar justru sedikit menurunkan skor (bias pilihan fold lain tidak selalu cocok), jadi manfaatnya berlaku untuk model produksi dan BiGRU, bukan semua model.

AFL per pasien

Uji detektor 50 Hz | angka = recall AFL rata-rata 5 ulangan | kolom pertama = versi sebelum revisi



Versi lama (kolom pertama) punya recall AFL lebih tinggi di beberapa pasien (misalnya 06426) karena lebih sering menebak AFL, dengan precision yang jauh lebih rendah (hal. 3). Di antara model sekarang, hanya pasien **08378** dan **04908** yang terdeteksi baik. **07910** (96 window) dan **08215** (9 window) jarang terdeteksi oleh versi mana pun, dan **06426** rendah di semua model sekarang. Karena kegagalannya sama di semua arsitektur, penyebabnya kemungkinan besar pola RR pasien itu sendiri (misalnya AFL dengan konduksi teratur yang mirip ritme normal), bukan pilihan model.



Dari mana AFL palsu berasal?
Sekitar **91%** AFL palsu model produksi muncul pada pasien yang memang punya episode AFL (terutama 04936 dan 04043), kemungkinan window di sekitar awal/akhir episode. Pada pasien tanpa AFL, alarm palsu paling banyak sekitar 12 window dari ±7.000 window per pasien. Pola seperti ini biasanya bisa dikurangi dengan menghaluskan prediksi antar-window (langkah 2).

Kesimpulan dan langkah berikutnya

Yang sudah pasti, yang perlu diputuskan, dan yang belum bisa dijawab

Keputusan

Hal	Status	Alasan
Ganti sistem lama (final.joblib + *find_peaks*) dengan pipeline revisi	**Disarankan kuat**	Front-end lama membuat Macro-F1 turun ke 0,418; di data uji yang sama pun revisi lebih baik
Tetap pakai MicroTransformer sebagai model produksi	Disarankan	Terbaik bersama BiGRU; BiGRU tidak lebih baik dan latihnya lebih lambat
Hentikan pencarian arsitektur RR-only (TCN, transformer lebih besar, dll.)	Disarankan	Empat arsitektur gagal di pasien AFL yang sama
Kalibrasi ulang *class_bias* produksi dengan grid −7…+3	**Menunggu persetujuan**	Mengubah file yang dipakai backend (hanya metadata .json)
Pakai protokol ini untuk semua eksperimen berikutnya	Disarankan	OOF dan fold sudah tersimpan; ide baru cukup dibandingkan berpasangan

Langkah 2 (berikutnya)

• **Smoothing antar-window.** Episode AFL berlangsung menit; menghaluskan prediksi window berurutan menargetkan AFL palsu di sekitar episode.

• **Ensemble MicroTransformer + BiGRU.** Skor keduanya setara tapi pola recall per pasiennya berbeda (mis. 06426).

• **Window AFL lebih rapat saat training saja.** Versi lama (stride AFL 1 detik) mengalahkan revisi tanpa bias; kemungkinan kepadatan itu bekerja sebagai augmentasi. Evaluasi tetap pakai stride 5 detik.

• **Bobot kelas lebih lunak.** Misalnya akar dari bobot sekarang, atau logit-adjusted loss, supaya tidak perlu koreksi bias sebesar −4,5.

• **Untuk 07910, 08215, 06426:** cabang input sinyal EKG mentah 50 Hz atau data AFL tambahan, karena info interval RR tampaknya tidak cukup.

Batasan

• Semua angka berasal dari 23 pasien AFDB yang di-downsample ke 50 Hz. Noise sensor, posisi elektroda, dan gerak pasien pada perangkat asli belum tersimulasi.

• Hanya 7 pasien AFL (1.152 window). CI AFL F1 selebar ±0,7: angka AFL adalah perkiraan kasar.

• Bias kelas dipilih dari data yang sama (cross-fit antar fold). Ini jujur di dalam CV, tapi tetap perlu dikonfirmasi pada data perangkat yang dilabeli dokter.

• Front-end lama disimulasikan pada lead 1 AFDB yang di-downsample ke 50 Hz; pada sinyal perangkat asli hasilnya bisa lebih baik atau lebih buruk.

Lampiran teknis

Konfigurasi, waktu komputasi, dan cara mereproduksi

Komponen	Nilai
Data	cache/dataset_v2_detector.npz — 165.978 window, 23 pasien
Pembagian	5 ulangan × 5 fold pasien, seed 2026; fold disimpan di folds.npz
Training DL	30 epoch, batch 256, AdamW lr 1e-3, weight decay 1e-4, cosine, weighted CE (sama dengan notebook revisi)
Seed latih	seed + 100·ulangan + fold
Bias kelas	grid −7…+3 langkah 0,25; cross-fit antar fold
Bootstrap	2.000 sampel, pasien diresampel per strata
Waktu per fold	LightGBM 3,4 s (CPU) · MicroTransformer 88 s (GPU) · ResNet1D 110 s (GPU) · BiGRU 429 s (CPU)
Versi lama	ekstraksi_hrv.py apa adanya (134.922 window, sama dengan model.ipynb) + MicroTransformer resep model.ipynb, dilatih ulang pada fold yang sama (45 s/fold, GPU); front-end lama: 167.454 window, 0 gagal (<2 puncak)
Total waktu	sekitar 1 jam 40 menit (kandidat) + 25 menit (versi lama) di WSL Debian, RTX 5060

File

File	Isi
v3_evaluasi_robust/evaluasi_robust.ipynb	Notebook evaluasi lengkap dengan output dan kesimpulan
v3_evaluasi_robust/sihedaf_cv.py	Fold berulang, training, bias kelas, metrik per pasien, bootstrap
v3_evaluasi_robust/eval_versi_lama.py	Ukur ulang versi sebelum revisi (v1_lama); hasil di .../versi_lama/
v3_evaluasi_robust/laporan/build_report.py	Pembuat laporan ini
cache/oof_robust/detector_e30_r5_s2026/	OOF tiap model × ulangan, folds.npz, ringkasan.csv, versi_lama/
tools/run_notebook.py	Runner notebook di WSL (kernel sihedaf-v2)

Mereproduksi

Semua perintah di WSL dari root repo. Notebook: `python tools/run_notebook.py v3_evaluasi_robust/evaluasi_robust.ipynb` (job yang OOF-nya sudah ada dilewati). Versi lama (±25 menit, bisa dilanjutkan): `cd v3_evaluasi_robust && python eval_versi_lama.py`. Laporan: `python v3_evaluasi_robust/laporan/build_report.py --extract`, lalu perintah yang sama tanpa argumen dengan Python yang memiliki ReportLab. Lihat README.md di root.