Laporan v4: smoothing antar-window & ensemble

Pasca-proses tanpa training, dibandingkan berpasangan dengan v3.1

+0,004
Δ Macro-F1, ensemble

0,51 → 0,09
Alarm palsu/jam, smoothing

74% → 38%
Deteksi episode, smoothing

v3.1
Paket produksi tetap

Window uji detektor 50 Hz, OOF v3 (5 ulangan × 5 fold pasien). Konfigurasi smoothing dan bias kelas dipilih per fold dari fold lain. "Smoothing" pada kartu = MicroTransformer + smoothing offline. Bukan uji pada perangkat asli.

Jawaban singkat
Tidak ada varian yang lebih baik dari v3.1. Ensemble MT + BiGRU setara (P = 0,72), jadi tidak sebanding dengan biaya melatih dan mengirim model kedua. Smoothing bukan perbaikan, melainkan **tukar-menukar**: alarm AFL palsu turun sekitar 6×, tetapi separuh episode AFL ikut hilang, terutama episode pendek. Paket produksi tetap v3.1; v4 tidak dikemas.

Hipotesis (ditetapkan sebelum melihat hasil)

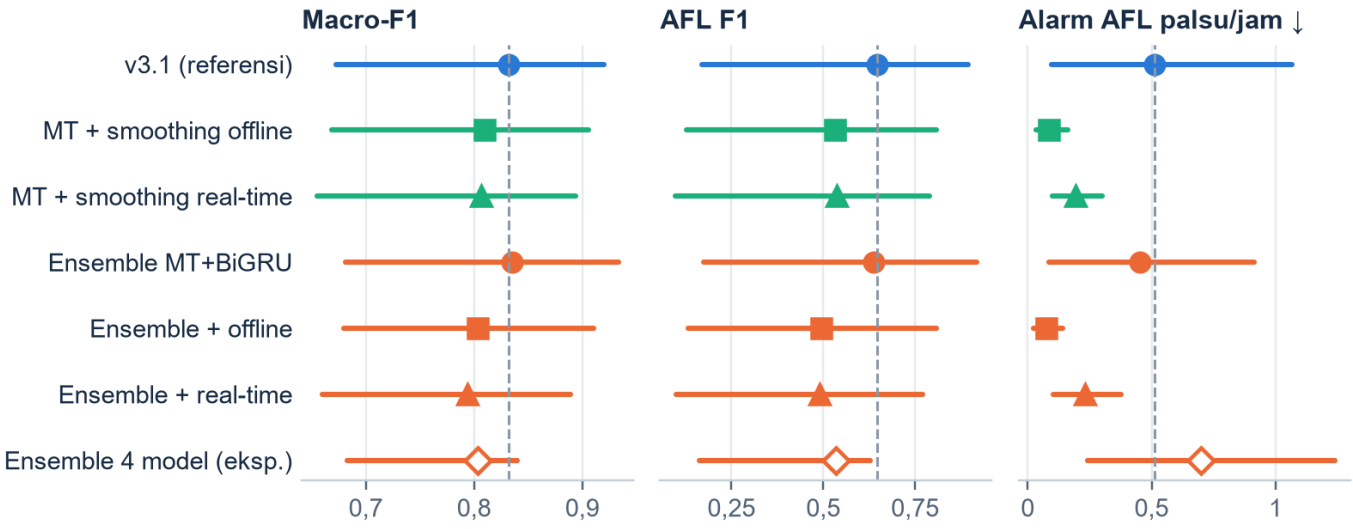
Varian	Macro-F1 vs v3.1	Alarm palsu/jam	Episode AFL terdeteksi
MicroTransformer + smoothing offline	tidak terbedakan (P = 0,11)	0,09 vs 0,51	38% vs 74%
MicroTransformer + smoothing real-time	lebih buruk (P = 0,03)	0,19 vs 0,51	45% vs 74%
Ensemble MT + BiGRU	tidak terbedakan (P = 0,72)	0,45 vs 0,51	74% vs 74%
Ensemble MT + BiGRU + smoothing offline	tidak terbedakan (P = 0,16)	0,08 vs 0,51	38% vs 74%
Ensemble MT + BiGRU + smoothing real-time	lebih buruk (P = 0,03)	0,23 vs 0,51	48% vs 74%

Ensemble 4 model diuji sebagai eksplorasi saja: tidak terbedakan dalam Macro-F1 dan alarm palsunya lebih banyak.

Hasil utama

Rata-rata 5 ulangan, CI 95% bootstrap pasien; alarm & episode dihitung per pasien lalu di-bootstrap

Varian	Macro-F1	AFL F1	AFL R	Normal R	Alarm palsu/jam	Episode terdeteksi
v1 (sebelum revisi), argmax	0,744 [0,64–0,81]	0,399 [0,09–0,59]	0,728	0,903	5,10 [2,69–7,89]	0,91 [0,73–1,00]
v3.1 referensi: MicroTransformer	0,832 [0,67–0,92]	0,647 [0,17–0,89]	0,592	0,924	0,51 [0,10–1,07]	0,74 [0,42–0,93]
MicroTransformer + smoothing offline	0,810 [0,67–0,91]	0,533 [0,13–0,81]	0,417	0,953	0,09 [0,03–0,16]	0,38 [0,08–0,64]
MicroTransformer + smoothing real-time	0,806 [0,65–0,89]	0,536 [0,10–0,79]	0,449	0,953	0,19 [0,10–0,30]	0,45 [0,18–0,65]
Ensemble MT + BiGRU	0,835 [0,68–0,93]	0,637 [0,17–0,92]	0,573	0,935	0,45 [0,09–0,91]	0,74 [0,42–0,94]
Ensemble MT + BiGRU + smoothing offline	0,803 [0,68–0,91]	0,494 [0,13–0,81]	0,382	0,965	0,08 [0,02–0,14]	0,38 [0,08–0,64]
Ensemble MT + BiGRU + smoothing real-time	0,794 [0,66–0,89]	0,490 [0,10–0,77]	0,407	0,959	0,23 [0,10–0,38]	0,48 [0,22–0,68]
Ensemble 4 model (eksploratif)	0,803 [0,68–0,84]	0,534 [0,16–0,63]	0,494	0,945	0,70 [0,24–1,24]	0,82 [0,60–0,97]



Cara membaca

Garis putus-putus = v3.1. Ada 13 episode AFL dalam 234 jam rekaman, jadi CI deteksi episode lebar. v1 terlihat paling banyak mendeteksi episode karena menebak AFL hampir di mana-mana (5,1 alarm palsu per jam).

Perbandingan berpasangan dengan v3.1

Δ = varian − v3.1 pada sampel bootstrap pasien yang sama

Varian	Δ Macro-F1	Δ AFL F1	Δ Normal R	Δ alarm/jam	Δ deteksi episode	Vonis Macro-F1
v1 (sebelum revisi), argmax	−0,088 [−0,16; −0,02]	−0,249 [−0,47; −0,05]	−0,020 [−0,03; −0,01]	+4,59 [2,58; 6,88]	+0,17 [0,03; 0,42]	lebih buruk
MicroTransformer + smoothing offline	−0,021 [−0,04; 0,02]	−0,114 [−0,19; 0,01]	+0,029 [0,02; 0,04]	−0,43 [−0,92; −0,05]	−0,35 [−0,65; −0,05]	tidak terbedakan
MicroTransformer + smoothing real-time	−0,025 [−0,05; 0,00]	−0,111 [−0,20; −0,02]	+0,029 [0,02; 0,04]	−0,32 [−0,79; 0,03]	−0,29 [−0,52; −0,05]	lebih buruk
Ensemble MT + BiGRU	+0,004 [−0,01; 0,02]	−0,011 [−0,04; 0,03]	+0,012 [0,01; 0,02]	−0,06 [−0,18; 0,02]	+0,00 [−0,04; 0,06]	tidak terbedakan
Ensemble MT + BiGRU + smoothing offline	−0,028 [−0,06; 0,02]	−0,153 [−0,25; 0,01]	+0,041 [0,02; 0,07]	−0,44 [−0,94; −0,06]	−0,35 [−0,65; −0,05]	tidak terbedakan
Ensemble MT + BiGRU + smoothing real-time	−0,038 [−0,07; 0,00]	−0,157 [−0,24; −0,04]	+0,036 [0,02; 0,06]	−0,28 [−0,75; 0,03]	−0,26 [−0,49; −0,05]	lebih buruk
Ensemble 4 model (eksploratif)	−0,029 [−0,09; 0,02]	−0,113 [−0,31; 0,02]	+0,021 [0,01; 0,04]	+0,19 [0,02; 0,37]	+0,08 [−0,03; 0,28]	tidak terbedakan

Yang konsisten (CI tidak menyentuh 0)

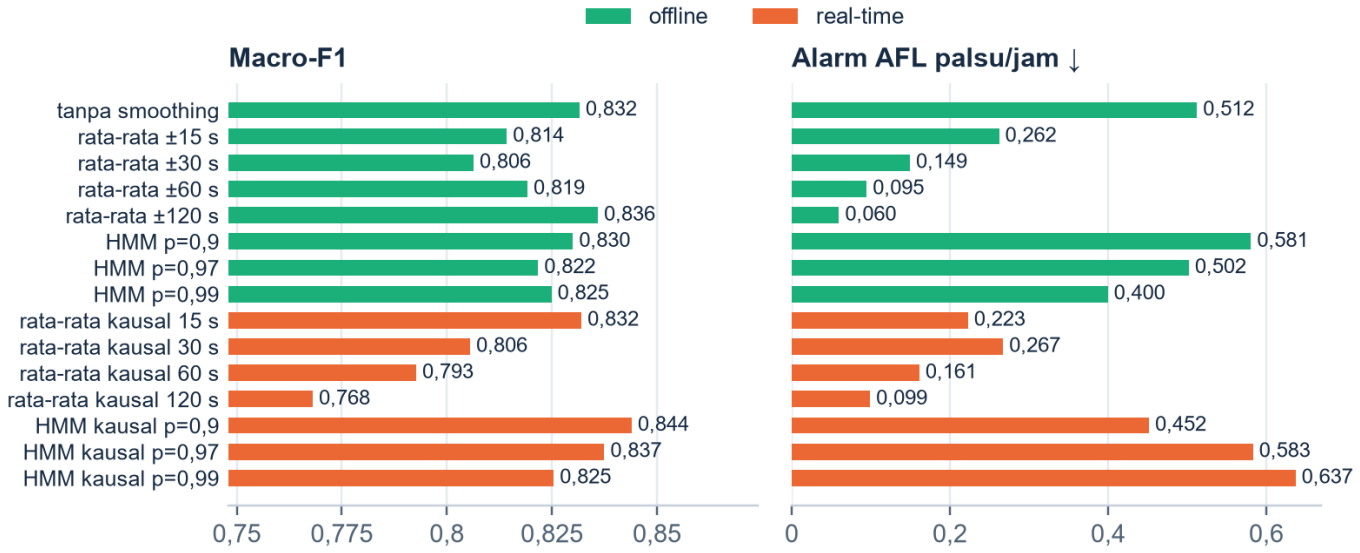
Smoothing offline menurunkan alarm palsu (−0,43 [−0,92; −0,05] per jam) dan menaikkan recall Normal (+0,029 [0,02; 0,04]), tapi juga menurunkan deteksi episode AFL (−0,35 [−0,65; −0,05]). Dalam Macro-F1 window ia tidak terbedakan dari v3.1. **Ensemble** hanya konsisten menaikkan recall Normal (+0,012 [0,01; 0,02]); Macro-F1, AFL F1, dan alarm palsunya tidak terbedakan. **Smoothing real-time** lebih buruk dalam Macro-F1.

Kenapa ini penting

Smoothing memindahkan sistem ke titik lain pada kurva yang sama: lebih sedikit alarm, lebih banyak AFL terlewat. Mana yang lebih baik bergantung pada pemakaian. Untuk skrining, AFL yang terlewat lebih mahal; untuk pemantauan rumah yang alarmnya mengganggu, sebaliknya. Ini keputusan produk, bukan hasil teknis.

Trade-off smoothing

Hasil jika satu konfigurasi dipaksa untuk semua fold (diagnostik, bukan seleksi jujur)



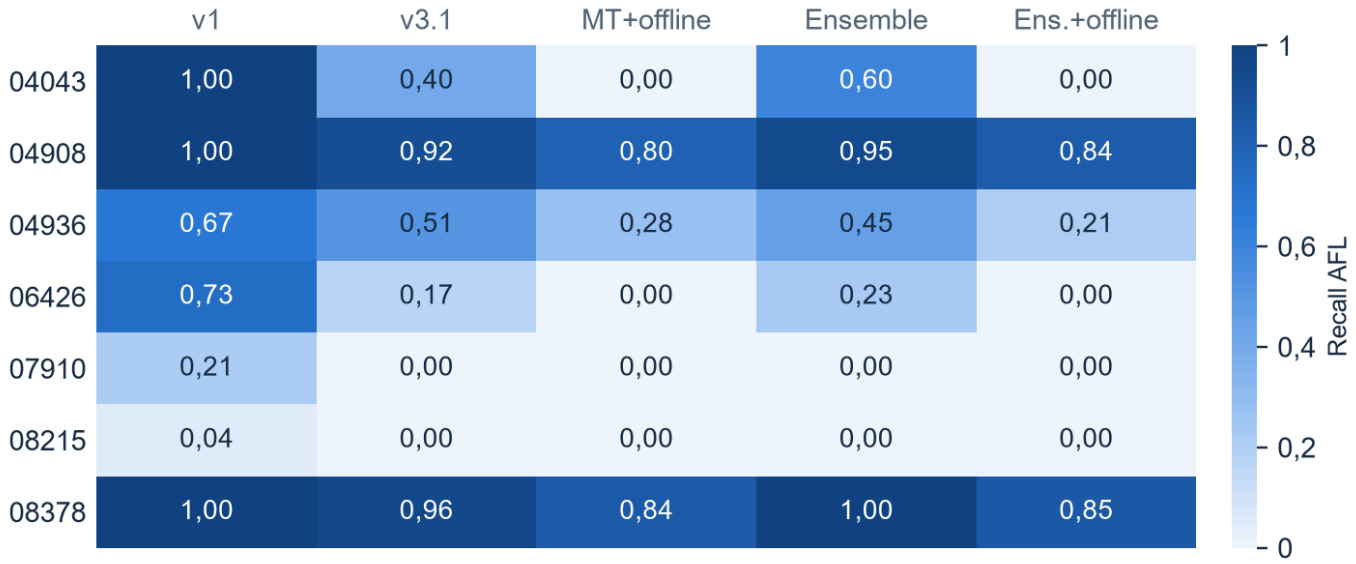
Varian	Konfigurasi terpilih cross-fit (dari 25 fold)
MicroTransformer + smoothing offline	rata-rata ±120 s (20×), rata-rata ±15 s (4×), rata-rata ±30 s (1×)
MicroTransformer + smoothing real-time	rata-rata kausal 120 s (18×), rata-rata kausal 30 s (3×), rata-rata kausal 15 s (2×)
Ensemble MT + BiGRU + smoothing offline	rata-rata ±120 s (20×), rata-rata ±15 s (5×)
Ensemble MT + BiGRU + smoothing real-time	rata-rata kausal 120 s (13×), rata-rata kausal 60 s (4×), rata-rata kausal 30 s (3×)

Yang terlihat

Semakin lebar smoothing, semakin sedikit alarm palsu (tanpa smoothing 0,51 → rata-rata ±120 s 0,06 per jam). Tapi AFL F1 tidak pernah melampaui tanpa smoothing (0,647). Pilihan cross-fit juga tidak stabil: konfigurasi berganti antar fold, dan kombinasi terbaik di tabel dipaksa ini tidak bisa dipakai sebagai klaim karena dipilih setelah melihat hasil.

AFL per pasien

Recall AFL rata-rata 5 ulangan; jumlah window AFL per pasien di laporan v3



Episode pendek hilang

Smoothing menghapus AFL pada pasien dengan episode pendek: 04043 (1 window) dan 06426 (21 window, ±2 menit) turun ke 0. Episode panjang (04908, 08378) tetap terdeteksi tapi recall-nya turun. Ensemble sedikit menaikkan 04043 dan 06426, tetapi tidak cukup untuk mengubah hasil keseluruhan. 07910 dan 08215 tetap tidak terdeteksi oleh varian mana pun.

Kesimpulan dan langkah berikutnya

Keputusan v4 dan rencana v5

Keputusan	Alasan
Paket produksi tetap v3.1; v4 tidak dikemas (tidak ada v4.1)	Tidak ada varian yang lebih baik secara konsisten
Ensemble MT + BiGRU tidak dipakai	Setara (P = 0,72); butuh model final kedua dan inferensi 2×
Smoothing tidak dijadikan default	Mengurangi alarm palsu tapi menghilangkan separuh episode AFL
Smoothing offline bisa jadi *opsi produk*	Jika tim memutuskan alarm palsu lebih mahal dari AFL terlewat. Perlu keputusan pemilik produk

Langkah berikutnya (v5, perlu training)

• **Window AFL rapat khusus training** (stride 1 s, evaluasi tetap 5 s). Petunjuk terkuat dari v3: resep v1 dengan stride itu lebih baik dari revisi tanpa bias.

• **Bobot kelas lebih lunak** (akar bobot sekarang / logit-adjusted loss), supaya model tidak bergantung pada bias −4,5.

• **Cabang EKG mentah 50 Hz** untuk 07910, 08215, 06426, yang gagal di semua versi berbasis interval RR.

Batasan

• Hanya 13 episode AFL di 7 pasien: metrik episode sangat kasar.

• Smoothing offline mengasumsikan rekaman utuh tersedia sebelum diputuskan (cocok untuk *predict_ecg* per rekaman, tidak untuk alarm seketika).

• Reproduksi: `python tools/run_notebook.py v4_smoothing_ensemble/smoothing_ensemble.ipynb` (±14 menit), lalu `laporan/build_report.py --extract` dan tanpa argumen.